

연구 계획서

미국 주식시장 주가 예측을 위한 다차원 LLM 기반 금융 뉴스 감성 분석:
거래비용을 고려한 실증적 평가

저자 [이름]

소속 / 과정 [학과, 대학교]

지도교수 [지도교수명]

작성일 2026년 9월 4일

예상 연구 기간 12개월

1. 초록

주가 예측을 위한 딥러닝 모델은 점차 금융 뉴스 감성을 보조 신호로 결합해왔으며, 대형언어모델(LLM)의 등장으로 어휘 기반(VADER) 및 인코더 기반(FinBERT) 베이스라인 대비 감성 추출의 품질이 향상되었다. 그러나 기존 연구 대부분은 감성을 단일 극성 점수로 단순화하거나, 성과를 거래비용을 반영한 실현 트레이딩 성과가 아니라 분류 정확도로 평가한다. 본 연구의 중심 질문은 'LLM이 주가를 더 잘 맞추는가'가 아니라, 'LLM이 뉴스에서 추출한 다차원 정보 중 어떤 부분이 단일 극성을 넘어 추가적인 미래수익 정보를 제공하며, 그 정보가 거래비용을 차감한 뒤에도 경제적 가치로 남는가'이다. 이를 위해 정보 이용 시점·진입·청산·백테스트 손익이 동일한 시간축을 공유하도록 통제된 환경에서 M0~M5 단계적 절제실험을 수행하고, 비용 차감 후 연율화 샤프비율을 단일 Primary 지표로 하여 검정한다. 예측 정확도에 대한 가설(H1)과 경제적 가치에 대한 가설(H2)은 서로 다른 결과일 수 있음을 명시적으로 구분하며, 본 연구의 핵심 주장은 H2에 있다.

2. 연구 배경 및 Novelty 진술

주가 움직임 예측은 계량 금융 및 머신러닝 분야에서 가장 많이 연구된 문제 중 하나이다. 효율적 시장 가설에 따르면 공개적으로 이용 가능한 정보는 이미 가격에 반영되어 있어야 하므로, 점 예측 정확도만으로는 실질적 가치를 판단하기 어렵다. 이 때문에 선행 연구들은 (i) 비정형 텍스트로 정보 집합을 확장하는 방향과, (ii) 실현된 경제적 성과로 모델을 평가하는 방향으로 발전해왔다.

확산 인지형(dissemination-aware) 감성과 맥락 정보를 결합해 주가 움직임을 예측하는 FinGPT 계열 연구가 이미 존재하므로, '정보확산 차원을 사용한다'는 것 자체는 독자적인 novelty로 방어할 수 없다. 따라서 본 연구는 novelty의 축을 '새로운 feature의 제안'이 아니라 '식별 설계'에 둔다.

Novelty 진술

본 연구의 기여는 새로운 감성 변수 하나를 제안하는 데 있지 않다. 정보 이용 시점부터 체결·청산까지 시간축이 정합화된 point-in-time 환경에서, 텍스트 감성의 다차원성과 정보확산의 한계 기여를 단계적 ablation(M0~M5)으로 식별하고, 그 예측력이 거래비용 차감 후에도 경제적 가치로 남는지를 단일 Primary 지표로 검정하는 데 있다.

3. 연구 질문 및 가설

3.1 연구 질문

- RQ1. 다차원 뉴스 감성은 가격정보만 사용하는 모델 대비 주가 방향 예측력을 개선하는가?
- RQ2. 극성·강도·불확실성·확산성 중 어떤 차원이 단일 극성을 넘어 추가적인 미래수익 정보를 제공하는가? (탐색적)
- RQ3. 예측력 개선은 거래비용을 차감한 뒤에도 경제적 가치로 남는가?
- RQ4. 이 경제적 가치는 변동성 및 기업 이벤트 국면에 따라 달라지는가? (탐색적)

3.2 가설

- H1 (주 가설):** 다차원 감성 모델(M5)은 가격 단독 모델(M0)보다 유의미하게 높은 방향성 예측 정확도(Macro-F1)를 달성한다.
- H2 (주 가설):** 다차원 감성 모델(M5)은 단일 극성 모델(M3) 대비, 거래비용 차감 후 더 높은 연율화 샤프비율과 더 높은 순수적수익률, 그리고 더 낮은 최대낙폭(MDD)을 보인다.

H1과 H2의 계층 관계

H1(예측 정확도)과 H2(경제적 가치)는 서로 다른 검정이며, H1이 성립해도 H2가 성립하지 않을 수 있다 (예: 방향성 예측은 개선되었으나 개선분이 소수의 큰 손실 국면에 집중되어 비용 차감 후 샤프비율이 오히려 낮아지는 경우). 본 연구에서 H1은 감성 정보가 통계적 예측력을 갖는지 확인하는 선행적 확인 절차(predictive validity check)로 위치시키며, 논문의 핵심 주장은 H2, 즉 예측력 개선이 거래비용 차감 후에도 경제적 가치로 남는가에 있다. 초록과 § 6.4의 Primary 지표 설계도 이 계층을 따른다.

RQ2(어떤 차원이 추가 정보를 제공하는가)와 RQ4(국면별 차이)는 사전 방향을 지정하지 않는 탐색적 분석으로 수행하며, § 6.4의 Exploratory 계층에서 보고한다. 결과가 어느 방향으로 나오더라도 논문의 핵심 주장(H1·H2)은 독립적으로 유지된다.

4. 선행연구 비교

연구	감성 차원	Horizon	평가 지표	비 용	본 연구와의 차별점
Shen & Zhang (2024), arXiv:2410.01987 — LLM(GPT-4o) vs FinBERT 비교	단일 극성	해당 없음 (문서 단위 분류)	분류 정확도(F1)	미 반 영	뉴스·리포트·공시 텍스트의 감성 "분류 성능"만 비교하며 추가 예측·트레이딩 성과로 이어지지 않음. 본 연구는 동일 비교를 실제 M0~M5 경제적 가치 검정까지 확장.
Liang, Liu, Wang, Yang, Zhang & Wang (2024), arXiv:2412.10823 — FinGPT (Dissemination-Aware & Context-Enriched LLM) ★핵심 비교 대상	극성 + 확산성(클러스터링 기반)	일 단위 이진 방 향성	이진 예측 정확도 (63% vs 55% baseline)	미 반 영	뉴스 클러스터링으로 확산성을 반영한 최초의 LLM 기반 연구이나, (i) point-in-time 유니버스 통제 없음, (ii) 거래비용 차감 성과 미검증, (iii) 강도·불확실성 차원 미분리. 본 연구는 이 세 gap을 명시적으로 채움 — novelty 진술(§ 2)의 직접 근거.
Dai, Ma, Liu, Geng & Wang (2026), arXiv:2603.11408 — Beyond Polarity: Multi-Dimensional LLM Sentiment Signals for WTI Crude Oil Futures	관련성·극성·강도·불확실성·전향성 5차원 (GPT-4o, Llama-3.2, FinBERT, AlphaVantage 비교)	주 단위	분류 성능, 변수 중요 도	미 반 영	다차원 LLM 감성이 단일 극성보다 우수함을 원자재 시장에서 입증한 선례. 다만 개별 주식이 아닌 단일 상품(WTI)·주 단위 horizon이며 트레이딩 성과·비용 미검증. 본 연구는 개별 종목·일 단위·비용 반영 트레이딩 성과로 확장(RQ2의 직접 근거).
Prata et al. (2024), <i>Artificial Intelligence Review</i> , 57(5) — LOBCAST	해당 없음 (LOB 기반)	다양 (tick 단 위)	표본 외 일 반화 성능 저하	부 분	직접 경쟁연구 아님. 15개 SOTA 딥러닝 모델이 신규 데이터에서 성능이 급격히 저하됨을 보인 벤치마크 연구로, 본 연구의 walk-forward·point-in-time 설계 필요성에 대한 일반화 경고 근거로만 인용.
Kumar, Sarangi & Verma (2021), <i>Materials Today: Proceedings</i> , 49, 3187–3191 — 체계적 리뷰	다양	다양	리뷰(정확도·RMSE 등 혼재)	다 양 (대 부 분 미 반 영)	ML·통계 기법 전반을 개관하나 감성 다차원성이나 거래비용 반영 평가는 다루지 않음 — 본 연구가 채우는 방법론적 공백을 확인하는 배경 문헌으로 인용.
Politis & Romano (1994), <i>JASA</i> , 89(428), 1303–1313; Harvey, Liu & Zhu (2016), <i>Review of Financial Studies</i> , 29(1), 5–68	해당 없음	해당 없음	통계 검정 방법론	해 당 없 음	각각 stationary bootstrap과 다중비교 유의수준 보정의 표준 방법론적 근거. § 6.4의 Primary/Robustness 검정 절차(block/stationary bootstrap, Benjamini–Hochberg 보정)에 직접 적용.

5. 데이터

표기법(Notation). j: 종목 인덱스 · t: 거래일(시점) 인덱스 · i: 개별 뉴스 기사 인덱스 · r_{t+1} : t+1일 목표 수익률 · σ_j : 종목 j의 훈련구간 내 수익률 표준편차 · s_i : 기사 i의 스칼라 감성 점수 · $S_{j,t}$: 종목-일 집계 감성 feature · $N_{j,t}$: 시점 t에 종목 j에 관련된 기사 집합 · K_i : 기사 i에 태깅된 종목 집합 · Δt_i : cut-off로부터 기사 i까지의 경과 시간 · SR: 연율화 샤프비율.

5.1 대상 종목군 및 Point-in-time 데이터

walk-forward 시점별 직전 252거래일 유동성 재산정 방식을 유지하되, 데이터 확보 경로를 다음 3단계로 명시한다.

경로	내용	novelty 영향
----	----	------------

경로 A (1순위)	상장폐지·합병·편입·편출 이력을 포함한 생존편향 없는 point-in-time 지수 구성 DB 확보 (학내 라이선스 또는 유료 구매)	§ 2 novelty 진술 원안 유지 가능
경로 B (차선)	공개 자료로 상장폐지 종목 목록을 부분 복원하여 근사 point-in-time 유니버스 구성	'부분적으로 통제된 환경'으로 표현 하향, 복원 한계를 § 8에 명시
경로 C (최후)	연구 시작 시점 기준 고정 유니버스 사용	novelty를 'point-in-time 통제'가 아니라 '시간축 정합화 + 비용 반영 식별 설계'로 축소 재정의

경로 A/B/C 중 무엇을 사용하든, 선택한 경로와 그로 인한 한계를 § 8에 명시하고, 가능한 경우 두 경로 결과를 병행 산출하여 유니버스 정의에 대한 민감도를 보고한다.

5.2 표본 기간

최소 4~5년(예: 2021~2026년)을 대상으로 하며, 서로 다른 변동성 국면을 포함하여 RQ4의 탐색적 분석이 가능하도록 한다.

5.3 데이터 소스

데이터 유형	주요 소스	비고
가격/거래량 (일간·분단위)	Alpaca Market Data API / Polygon.io	시가·종가 및 장중 데이터 확보
종목 태깅 뉴스	Alpaca News API (Benzinga 제공) / Finnhub	티커 태깅·발행 타임스탬프·매체 메타데이터 포함
기업 이벤트 (실적, 공시)	SEC EDGAR / Finnhub 실적 캘린더	국면 분석용 이벤트 구간 정의
Point-in-time 지수 구성	§ 5.1 경로 A/B/C 중 확정된 소스	사전 확인 필요
감성 추출 (기본)	FinBERT 계열 + 규칙 기반 보조 지표	§ 6.2 Plan A — 전 표본 처리
감성 추출 (LLM)	GPT-4o 등 상용 LLM	§ 6.2 — 예산 범위 내 표본에 적용

5.4 예측 대상 및 실행 모델 정의

정보 cut-off와 체결 시점 사이에 실행 여유(execution buffer)를 명시적으로 둔다.

- 정보 cut-off:** t+1 거래일 09:25 ET. 이 시점까지 공개된 뉴스·가격 정보만을 feature 산출에 사용한다 (장중·시간외·프리마켓 뉴스 모두 동일 규칙 적용).
- 실행 여유(execution buffer):** cut-off와 체결 사이 5분. 이 구간에서 모델 추론과 주문 생성이 이루어진다고 가정한다.
- 진입 시점·가격:** t+1 거래일 정규장 시가(Open, 09:30 ET).
- 청산 시점·가격:** t+1 거래일 정규장 종가(Close). 보유기간 1일, 오버나이트 갭 익스포저 없음.
- 예측 target:** 정보 cut-off·진입가·청산가·백테스트 손익이 모두 정합적인 하나의 시간축을 공유하도록, 목표 변수는 다음과 같이 정의한다.

$$r_{t+1} = \frac{\text{Close}_{t+1}}{\text{Open}_{t+1}} - 1$$

- 분류 threshold:** 각 walk-forward 훈련 구간 내부에서 산정한 종목별 수익률 표준편차 σ_j 기준 $\pm 0.5 \times \sigma_j$ 를 기본 스킴으로 하여 3-class 레이블을 부여한다 (변동성 크기가 다른 종목 간 횡단면 비교 타당성 확보).

$$y_{t+1} = \text{sign}(r_{t+1}) \cdot \mathbb{1}\{|r_{t+1}| > 0.5 \sigma_j\}$$

- Cut-off 민감도:** 09:20 / 09:25 / 09:29 ET의 세 조건을 강건성 분석으로 비교하여, 결과가 실행 여유 가정에 얼마나 민감한지 보고한다.

해석 범위: 09:25 ET cut-off와 5분의 실행 여유는 실제 기관 실행 환경을 정확히 재현한 것이 아니라, 재현 가능한 표준화된 연구용 체결규칙이다. 실제 체결 가능성에 대한 판단은 이 표준 규칙의 결과를 그대로 신뢰하기보다, § 6.5.2의 worst-case 슬리피지(30bp) 시나리오를 통해 보수적으로 평가한다.

5.5 감성 변수 정의 및 확산성 임계값

텍스트 감성(극성·강도·불확실성)과 정보확산(확산성)의 개념적 분리는 유지하되, 임계값 선택을 데이터 기반으로 정당화한다.

임계값 결정 절차

수작업으로 라벨링한 소규모 validation set(동일 사건 여부가 표기된 기사 쌍 약 200~300쌍)을 구축한다. 시간창(2/4/8시간)과 코사인 유사도 (0.75/0.80/0.85/0.90)의 조합별로 사건 클러스터링의 precision·recall·F1을 산출하고, F1이 최대가 되는 조합을 주 기준으로 채택한다. 채택된 값과 그 근거 지표를 논문에 표로 제시한다.

항목	정의	결정 방식	비고
사건 클러스터링 시간창	동일 사건으로 묶는 재보도 시간 간격	validation set F1 최대화 (후보: 2/4/8시간)	잠정 기본값 4시간
헤드라인 유사도 임계값	임베딩 코사인 유사도 기반 동일 사건 판정	validation set F1 최대화 (후보: 0.75~0.90)	잠정 기본값 0.85
중복·재전송 처리	AP/Reuters 등 통신사 기사의 복수 매체 재게재	동일 통신사 출처(byline·신디케이션 태그)는 1건으로 집계	매체 메타데이터 기반 규칙
매체 신뢰도 필터	봇 스크래핑·저품질 매체 노이즈 배제	사전 정의된 '독립 주요 매체' 목록 내 매체만 확산성 카운트에 포함	필터 미적용 결과와 병행 비교

록어헤드 안전성 규칙: 시점 t의 확산성 값은 t 이전에 실제로 관측된 기사만으로 계산하며, t 이후의 재보도는 그 시점 이후의 feature에만 반영한다. 이 규칙은 파이프라인 단위테스트로 검증한다.

즉, 두 헤드라인 임베딩 벡터 h_a, h_b 간 코사인 유사도가 임계값 θ 이상이면 동일 사건으로 판정한다.

$$\cos(\vec{h}_a, \vec{h}_b) = \frac{\vec{h}_a \cdot \vec{h}_b}{\|\vec{h}_a\| \|\vec{h}_b\|} \geq \theta, \quad \theta \in \{0.75, 0.80, 0.85, 0.90\}$$

Threshold selection bias 방지

시간창·유사도 임계값을 F1이 최대가 되는 조합으로 '선택'하는 절차 자체가, 그 validation set을 이후 최종 성능 평가에 재사용할 경우 threshold selection bias를 유발할 수 있다. 이를 방지하기 위해 (1) 임계값 선택 전용 validation set(사건쌍 약 200~300쌍)과 (2) 최종 M0~M5 성능·경제적 가치 평가에 사용하는 walk-forward test 구간을 완전히 분리한다. 임계값은 (1)에서만 확정하며, (2)의 어떤 데이터도 임계값 산정에 재사용하지 않는다. 이 분리는 § 5.5· § 5.6의 모든 threshold(시간창, 유사도, decay half-life 등)에 동일하게 적용한다.

5.6 관련성(Relevance) 및 뉴스 집계 규칙

- 관련성 정의:** 뉴스 API가 발행 시점에 부여한 티커 태깅을 1차 기준으로 사용한다. 단일 종목만 태깅된 기사는 관련성 1.0, 복수 종목이 태깅된 기사는 1/(태깅 종목 수)로 배분한다. 헤드라인에 해당 기업명·티커가 직접 등장하는 경우 가중치를 상향하는 규칙을 추가할 수 있으나, 이는 기사 텍스트만으로 판정 가능한 결정론적 규칙에 한한다.
- LLM이나 사후 정보를 이용한 관련성 판정은 사용하지 않는다. 관련성 산출에 미래 가격 반응이 개입할 여지를 원천 차단하기 위함이다.
- 관련성 가중:** 기사 i가 태깅된 종목 집합을 K_i 라 할 때, 관련성 가중치는 다음과 같이 균등 배분한다.

$$w_i^{\text{rel}} = \frac{1}{|K_i|}$$

- 시간감쇠 파라미터:** decay half-life $h = 6$ 시간으로 사전 고정한다. 기사 i의 발행 시각과 cut-off 사이 경과 시간을 Δt_i 라 하면, 시간감쇠 가중치는 다음과 같다.

$$w_i^{\text{decay}} = \exp(-\lambda \Delta t_i), \quad \lambda = \frac{\ln 2}{h}, \quad h = 6 \text{ hours}$$

즉 cut-off로부터 6시간 이전에 발행된 기사의 가중치는 최신 기사 대비 1/2로 감소한다. 이 값은 3시간·12시간의 두 조건으로 강건성 분석에서 비교하며, § 5.5의 threshold selection bias 방지 원칙과 동일하게 최종 test 구간의 데이터로 half-life를 재조정하지 않는다.

- 집계 규칙(모든 감성 소스에 동일 적용):** 종목-일 feature는 관련성 가중 $\times$ 시간감쇠 가중의 가중평균으로 산출한다. 시점 t 기준 종목 j에 대해 그 날 발행된 뉴스 집합을 $N_{j,t}$, 개별 기사의 스칼라 감성 점수를 s_i 라 하면 다음과 같다.

$$S_{j,t} = \frac{\sum_{i \in N_{j,t}} w_i^{\text{rel}} w_i^{\text{decay}} s_i}{\sum_{i \in N_{j,t}} w_i^{\text{rel}} w_i^{\text{decay}}}$$

- 이 단일 집계 규칙은 M1(VADER)부터 M5(LLM 전체)까지 예외 없이 동일하게 적용한다.
- 대안 집계 방식(단순 평균, 최신 기사만 사용)은 강건성 분석에서 별도 비교한다.

5.6.1 감성 점수의 스칼라화(Scalarization) 수식

정규화(§ 5.7)는 서로 다른 스케일을 맞추는 절차이지만, 그 이전에 각 도구의 원본 출력을 하나의 스칼라 감성 점수로 변환하는 규칙 자체가 명시되어야 한다. 특히 FinBERT는 3-class 확률 분포를 출력하므로 별도의 변환식이 필요하다.

- **FinBERT:** 3-class 확률 분포에서 다음과 같이 스칼라 점수를 산출한다. (P(neutral)은 스칼라 점수에는 직접 반영하지 않되, 불확실성(§ 5.5 텍스트 감성 차원) 산출 시 보조 지표로 활용할 수 있다.)

$$s_i^{FinBERT} = P(positive) - P(negative)$$

- **VADER:** compound score를 그대로 스칼라 극성 점수로 사용한다 (-1~1 범위).
- **LLM(GPT-4o):** § 6.2의 구조화된 출력에서 정의한 극성 척도 점수를 그대로 사용한다.
- 이 변환은 § 5.7의 정규화 이전 단계로, M1~M5 전 모델에 동일한 절차로 적용하며 논문에 수식으로 명시하여 재현 가능하게 한다.

5.7 감성 점수 스케일 정규화

동일한 집계 규칙을 적용하더라도 VADER(-1~1 연속), FinBERT(3-class 확률), LLM(척도 기반 점수)은 점수의 정의와 분포가 서로 다르다. 정규화 없이 비교하면 모델 간 성능 차이가 '정보량의 차이'가 아니라 '스케일의 차이'에서 발생할 수 있어, M1~M5 비교의 공정성이 훼손된다.

훈련 구간 전체의 단일 통계량 대신, 시점 t 기준 과거 252거래일의 롤링(rolling) 평균·표준편차를 사용하여 point-in-time 정규화를 수행한다.

- 모든 감성 점수는 시점 t 기준 과거 252거래일 롤링 윈도우의 평균·표준편차로 z-score 정규화한다. 이는 훈련·검증·테스트 구간 전체에 동일하게 적용되는 절차이며, 어떤 시점에서든 t 시점 이후의 데이터를 정규화 파라미터 산정에 사용하지 않는다.

$$\widehat{S}_{j,t} = \frac{S_{j,t} - \mu_{j,t}^{(252)}}{\sigma_{j,t}^{(252)}}$$

여기서 평균 μ 와 표준편차 σ 는 t 시점 이전 252거래일만을 사용한 롤링 통계량이다.

$$\mu_{j,t}^{(252)} = \frac{1}{252} \sum_{\tau=t-252}^{t-1} S_{j,\tau}, \quad \sigma_{j,t}^{(252)} = \sqrt{\frac{1}{252} \sum_{\tau=t-252}^{t-1} (S_{j,\tau} - \mu_{j,t}^{(252)})^2}$$

- 연구 초기(롤링 윈도우 252일이 아직 채워지지 않은 구간)는 이용 가능한 과거 데이터만으로 축소된 윈도우를 사용하거나, 해당 구간을 분석에서 제외하는 방식 중 하나를 사전에 정하여 명시한다.
- 분포가 심하게 비대칭이거나 이산적인 경우(예: FinBERT의 3-class 출력)를 고려하여, 동일한 롤링 원칙을 적용한 횡단면 순위 정규화(cross-sectional rank normalization) 버전도 산출하고 강건성 분석에서 비교한다.
- 정규화 절차는 M1~M5 전 모델에 동일하게 적용하며, 절차 자체(윈도우 길이, 초기 구간 처리 방식 포함)를 논문에 명시하여 재현 가능하게 한다.

6. 연구 방법론

6.1 절제실험(Ablation) 설계

모델	Price	Polarity	Intensity	Uncertainty	Diffusion	해석
M0 Price-only	O	X	X	X	X	가격정보 baseline
M1 Price+VADER	O	VADER	X	X	X	사전 기반 감성의 효과
M2 Price+FinBERT	O	FinBERT	X	X	X	금융 특화 인코더 감성의 효과
M3 Price+LLM Polarity	O	LLM	X	X	X	LLM이 단일 극성에서 만드는 추가 효과
M4 Price+LLM 3D	O	LLM	O	O	X	극성→다차원 텍스트감성의 효과
M5 Full (3D+Diffusion)	O	LLM	O	O	O	정보확산 차원의 추가 효과

6.2 감성 추출 전략

극성·강도·불확실성이라는 3차원 추론을 소량의 라벨만으로 경량 모델에 학습시키는 접근은 머신러닝 실무 관점에서 비현실적이며, 그 경우 최종 M3~M5 feature 대부분이 경량 모델에서 생성되어 '이 논문이 검증하는 LLM은 무엇인가'라는 정체성 문제가 발생한다. 이에 따라 감성 추출 전략을 아래 3개 Plan으로 구

성한다.

Plan	내용	적용 범위	위상
Plan A (기본)	M1·M2는 VADER·FinBERT로 전 표본 처리. M3~M5의 LLM 감성은 예산 범위 내에서 사전 고정된 핵심 표본(core sample)에 GPT-4o를 직접 적용	고정된 핵심 표본 전체	본 연구의 기본 설계 — 이것만으로 H1·H2 검정 가능
Plan B (예산 초과 시)	core sample 자체를 조정하지 않고, LLM 호출 대상 뉴스를 사전 정의된 기계적 규칙으로 필터링하여 호출 수만 축소	필터링된 표본 (robustness 전용)	예산 제약 대응 — Primary/Secondary 분석에는 사용하지 않고 robustness로만 병행 보고
Plan C (Optional Extension)	충분한 라벨(수천 건 규모)이 확보될 경우에 한해 경량 모델 파인튜닝을 시도하고, 소표본에서 GPT-4o 직접 생성 vs 경량 모델 생성의 예측력·트레이딩 성과를 비교	여력이 있을 때만	필수 연구질문이 아닌 비용 최적화 부가 기여 — § 9.2 Fail-fast 대상

Core sample 사전 고정 원칙

core sample을 결과를 보기 전 연구 시작 시점에 관측 가능한 사전 지표만으로 확정한다: 연구 시작 시점 기준 시가총액 상위 100종목(S&P 100 대형주에 준하는 규모)을 core sample로 고정하고, 이후 중간 결과에 따라 조정하지 않는다. 예산이 부족할 경우 종목을 줄이는 대신 § 5.2의 표본 기간을 단축하여 core sample의 종목 구성은 유지한다.

Plan B 필터링 기준(객관화): 예산이 그래도 부족할 경우, core sample 종목은 유지한 채 뉴스만 '직전 5거래일 실현변동성 상위 20%에 해당하는 날'에 발행된 뉴스로 한정하여 LLM 호출 대상을 줄인다. 이 규칙은 사전에 결정된 기계적 기준이며, 결과를 본 뒤 표본을 재조정하는 절차는 포함하지 않아 체리피킹 편향을 차단한다. Plan B로 생성한 결과는 § 6.4의 Primary·Secondary 분석에 사용하지 않고 Robustness 분석에서만 Plan A 결과와 비교한다.

핵심 원칙: 본 논문이 검증하는 LLM 감성은 Plan A의 GPT-4o 직접 생성분이다. Plan C는 성공할 경우 '경량 모델로도 동등한 경제적 결과를 얻을 수 있다'는 부가 기여가 되지만, 실패하더라도 H1·H2 검정에는 영향을 주지 않는다. Plan C는 연구 성공조건이 아니라 여력이 있을 때 수행하는 부가 실험으로만 취급한다.

6.2.1 측정 타당성 검증

- 골드표준 표본에 대해 2~3명의 독립 annotator가 사전 정의된 기준표에 따라 라벨링하고, 순서형 변수는 Krippendorff's α 또는 가중 Cohen's κ , 연속형 변수는 ICC로 일치도를 산출한다.
- 실제 annotator 인원, 총 라벨링 건수 N, 소요 시간과 비용을 확정하여 § 9 일정에 반영한다.
- 프롬프트 원문, JSON 스키마, 모델 버전, temperature를 고정·기록하고, 동일 뉴스 재실행에 따른 점수 변동(재현성)을 보고하여 LLM의 확률적 출력이 결과를 좌우하지 않음을 확인한다.

6.3 예측 모델

백본 아키텍처로는 Transformer 계열 시계열 모델(PatchTST 또는 iTransformer)을 주 모델로, LSTM을 비교 베이스라인으로 사용한다. 모든 모델은 § 5.1의 유니버스 갱신 규칙 및 § 5.4의 정합화된 target 정의와 일치하는 walk-forward 방식으로 학습한다.

6.4 Primary 지표 및 분석 계층

Primary economic endpoint를 '거래비용 차감 후 연율화 샤프비율' 단 하나로 확정한다. 순누적수익률과 최대낙폭은 secondary metric으로 보고한다. 일별 순포트폴리오 수익률 $r_{p,t}^{net}$ 은 총수익률에서 회전율에 비례한 거래비용을 차감하여 산출한다.

$$r_{p,t}^{net} = r_{p,t}^{gross} - c \cdot Turnover_t$$

Primary 지표인 연율화 샤프비율은 다음과 같이 정의한다 (거래일 기준 연 252일 가정).

$$SR = \frac{\sqrt{252} \, r_p^{net}}{\sigma(r_p^{net})}$$

구분	검정 내용	지표	역할
Primary	M0 vs. M5 (long-only, 비용 차감 후)	연율화 샤프비율 (단일 지표)	논문의 핵심 주장 — H1·H2, RQ1·RQ3
Secondary	M3 vs. M4, M4 vs. M5	샤프비율 + 순누적수익률, MDD	RQ2 — 어느 차원이 추가 기여를 하는지 분해

Robustness	M1/M2 비교, LSTM 아키텍처, long-short, 비용 민감도(5/10/20/30bp), cut-off 민감도(09:20/09:25/09:29), 정규화 방식 비교, 유니버스 정의 비교	동일 지표군	결과가 특정 설계 선택에 좌우되지 않음을 확인
Exploratory	국면별(고/저변동성, 실적 전후) 상호작용, SHAP 귀속, threshold 대안	동일 지표군	RQ2·RQ4 — 사전등록 없이 탐색적으로 보고

- **Primary 검정:** M0 vs. M5의 비용 차감 후 연율화 샤프비용 차이에 대해 block bootstrap 또는 stationary bootstrap으로 신뢰구간을 산출한다.
- **평가 단위:** 통계 검정의 기본 단위는 같은 날짜·같은 종목에 대한 M0/M5 예측을 짝지은 paired evaluation으로 한다. 이는 두 모델이 동일한 시장 상황에 노출된 상태에서 비교되도록 하여 국면 차이로 인한 혼란을 줄인다.
- **최소 경제적 유의수준(MESI):** 통계적 유의성(신뢰구간이 0을 포함하지 않음) 외에, 연구 착수 시 사전에 지정한 최소 경제적으로 의미 있는 개선폭을 함께 제시한다.

$$\Delta SR = SR_{M5} - SR_{M3} \geq 0.1$$

통계적으로 유의하지만 이 최소 기준에 못 미치는 개선은 '통계적으로 검출되었으나 경제적으로는 미미함'으로 별도 해석한다.

- **Secondary 검정:** 동일 절차(paired evaluation, bootstrap)를 적용하되 Primary 대비 부차적 근거로 명시한다.
- Robustness·Exploratory에서 발생하는 다중 비교는 Benjamini-Hochberg 절차로 보정하며, 이 결과들이 Primary 결론의 신뢰성을 좌우하지 않도록 논문 구조상 명확히 구분한다.
- 국면별 분석은 하위표본 병렬 비교가 아니라 회귀모형 내 interaction term으로 검정하고 Exploratory로 표기한다.
- LOBCAST는 직접 경쟁연구가 아닌 '금융 ML 모델의 표본 외 일반화 실패 가능성'에 대한 방법론적 경고 근거로만 인용한다.

6.5 거래 전략, 포트폴리오 구성 및 비용 모델

6.5.1 포지션 사이징 및 포트폴리오 비중

- **기본 전략(Primary):** 상승 예측 종목에 대한 동일 비중(equal-weight) long-only 포트폴리오.
- **확장 전략(Secondary/Robustness):** M4/M5의 강도(Intensity) 또는 확산성(Diffusion) 점수가 높을수록 비중을 상향하는 순위 기반 가중(rank-based weighting) 포트폴리오.
- Long-short 전략은 Robustness 범주로 병행 보고하며, 종목별 공매도 가능 여부와 차입비용(borrow cost)을 반영한다.

6.5.2 거래비용 모델

- 거래비용은 commission, bid-ask spread, market impact/slippage 세 요소로 분해한다.
- 유동성 상위 미국 대형주에 대한 실증적 거래비용 추정치(공개 자료·중개사 수수료 체계)를 조사하여 중심값을 설정하고, 그 주변에서 5/10/20/30bp 민감도 분석을 수행한다.
- **실행 여유(§ 5.4) 리스크의 흡수:** 09:25~09:30 ET의 5분은 프리마켓 변동성이 커지는 구간으로, 이 구간에 발표되는 거래소 공시·속보를 반영하지 못할 위험이 있다. 이 리스크를 별도로 모델링하는 대신, 30bp worst-case 슬리피지 시나리오가 해당 정보손실 위험을 보수적으로 흡수한다고 명시하고, Primary 분석은 표준화된 연구용 체결규칙(§ 5.4)을 기준으로 하되 실제 체결 가능성에 대한 판단은 이 worst-case 시나리오 결과로 보수적으로 평가한다.

7. 기대 기여

1. 정보 cut-off·진입·청산·백테스트 손익이 하나의 시간축을 공유하도록 정합화하고, 실행 여유까지 반영한 설계 하에서 뉴스 감성의 경제적 가치를 검증
2. M0~M5 절제실험과 단일 Primary 지표 체계를 통해, 감성 정보원과 차원 확장의 한계 기여를 통계적으로 방어 가능한 형태로 분리
3. 관련성 산출 규칙과 점수 정규화 절차를 명시함으로써, 서로 다른 감성 도구(VADER/FinBERT/LLM) 간의 공정한 비교 프로토콜을 제시
4. (Plan C 성공 시 부가 기여) 경량 모델이 상용 LLM과 동등한 경제적 결과를 낼 수 있는지에 대한 실증적 비교

8. 한계 및 위험 요인

- § 5.1의 경로 B 또는 C를 택할 경우 생존편향이 완전히 제거되지 않으며, 이 경우 § 2 novelty 진술의 강도를 확보 수준에 맞게 하향 조정한다.
- Plan A/B에서 LLM 적용 대상 표본을 축소·필터링할 경우, 표본 선택으로 인한 편향 가능성이 존재하므로 선택 기준을 명시하고 결과 해석 범위를 제한한다.
- 확산성 임계값은 validation set 기반으로 선택하더라도 라벨링 표본의 대표성에 의존하므로, 민감도 분석 범위를 벗어난 조건에서는 결과가 달라질 수 있다.
- 1일 보유·시가 진입·종가 청산 전략은 오버나이트 익스포저를 배제하므로, 오버나이트 리스크를 갖는 전략과는 성과가 다를 수 있다.

- Cut-off를 09:25 ET로 두어도 실제 기관 실행 환경과는 차이가 있으며, 시가 체결 시 슬리피지가 가정보다 클 수 있다.
- 탐색적 분석(RQ2·RQ4)은 하위표본 축소에 따른 검정력 저하 위험이 있으므로 확증적 결론의 근거로 사용하지 않는다.
- 석사 과정생 1인이 LLM 감성 파이프라인과 백테스트 엔진을 동시에 구축하는 데 따르는 일정 리스크가 존재하며, § 9.2의 Fail-fast 기준으로 관리한다.

9. 연구 일정 및 Fail-fast 관리

9.1 연구 일정 (12개월)

단계	기간	주요 활동
1. 데이터 파이프라인 구축	1~2개월	유니버스 로직, 확산성 룩어헤드·중복제거 로직, 관련성·집계·정규화 규칙(§ 5.6~5.7) 구현 및 단위테스트
2. 감성 추출 및 타당성 검증	2~4개월	validation set 구축 및 임계값 확정(§ 5.5), Plan A 기반 감성 추출, annotator 검증
3. 베이스라인 모델 개발 (M0~M3)	4~6개월	가격 단독 및 단일 극성 계열 모델, walk-forward 파이프라인
4. 다차원·확산 모델 확장 (M4~M5)	6~8개월	3D 감성 및 확산성 결합 모델, 6개 모델 비교
5. 경제적 평가 및 Primary 검정	8~10개월	equal-weight long-only 백테스트, Primary(샤프비율) bootstrap 검정, Secondary 분해
6. Robustness·Exploratory 및 논문 작성	10~12개월	민감도·강건성 분석, 국면 상호작용, SHAP, 논문 초안 및 수정

9.2 Fail-fast 판정 기준

석사 과정 1인이 LLM 파이프라인과 퀀트 백테스트 엔진을 동시에 구축하는 일정에는 병목이 발생하기 쉽다. 특정 단계에서 진척이 없을 때 '언제 포기하고 다음으로 넘어갈지'를 사전에 정해두지 않으면, 부차적 과제에 시간을 소진하고 핵심 검정을 완료하지 못하는 최악의 결과가 발생한다.

판정 시점	점검 항목	통과 기준	미달 시 조치
2개월 말	데이터 파이프라인	룩어헤드 단위테스트 전부 통과, 종목·일 feature 산출 완료	종목 수·표본 기간 축소하여 재시도
4개월 말	감성 추출 (Plan A)	핵심 표본에 대한 LLM 감성 점수 산출 완료 및 annotator 일치도 확보	Plan B로 전환 — § 6.2에 사전 정의된 기계적 필터링 규칙(직전 5거래일 실현변동성 상위 20% 뉴스)만 적용, 임의 표본 조정 없음
6개월 말	M0~M3 베이스라인	walk-forward 예측 및 초기 백테스트 결과 산출	아키텍처를 LSTM 단일로 축소하여 진행
8개월 말	M4~M5 확장	6개 모델 전체 결과 산출	M4를 생략하고 M0/M3/M5 3개 모델로 축소
10개월 말	Primary 검정	M0 vs. M5 샤프비율 검정 완료	Robustness·Exploratory 전면 축소, 논문 작성 착수
상시	Plan C (경량 모델 파인튜닝)	2주 내 초기 성능이 FinBERT 수준 이상	즉시 중단 — 본 연구의 필수 요소가 아님

9.2.1 범위 축소 우선순위

일정 압박이 발생할 경우, 다음 순서로 항목을 축소한다. 뒤로 갈수록 논문의 핵심 주장에서 멀다.

1. Exploratory (국면 상호작용, SHAP, threshold 대안 비교)
2. SHAP 귀속 분석
3. Long-short 전략 (§ 6.5.1 확장 전략)
4. LSTM 대체 아키텍처 비교
5. Rank-based weighting 포트폴리오
6. 정규화 방식 간 추가 비교 (순위 정규화 vs. z-score 등 강건성 비교)

절대 유지 항목 (축소 대상 아님): 다음은 어떤 일정 압박 상황에서도 축소하지 않는다: (1) point-in-time·시간축 정합성(§ 5.1, § 5.4), (2) M0/M3/M4/M5 4개 핵심 모델, (3) Primary 검정(비용 차감 후 연율화 샤프비율, M0 vs. M5), (4) 거래비용 모델(§ 6.5.2), (5) § 6.2.1의 최소한의 감성 측정 타당성 검증(annotator

일치도). 이 5가지가 유지되는 한, 다른 모든 요소를 축소하더라도 논문의 핵심 주장은 방어 가능하다.

10. 참고문헌

1. Shen, Y., & Zhang, P. K. (2024). Financial Sentiment Analysis on News and Reports Using Large Language Models and FinBERT. *arXiv preprint arXiv:2410.01987*.
2. Liang, Y., Liu, Y., Wang, N., Yang, H., Zhang, B., & Wang, C. D. (2024). FinGPT: Enhancing Sentiment-Based Stock Movement Prediction with Dissemination-Aware and Context-Enriched LLMs. *arXiv preprint arXiv:2412.10823*.
3. Dai, D., Ma, D., Liu, D., Geng, K., & Wang, Y. (2026). Beyond Polarity: Multi-Dimensional LLM Sentiment Signals for WTI Crude Oil Futures Return Prediction. *arXiv preprint arXiv:2603.11408*.
4. Prata, M., Masi, G., Berti, L., Arrigoni, V., Coletta, A., Cannistraci, I., Vyetenko, S., Velardi, P., & Bartolini, N. (2024). LOB-based deep learning models for stock price trend prediction: a benchmark study. *Artificial Intelligence Review*, 57(5), Article 116.
5. Kumar, D., Sarangi, P. K., & Verma, R. (2021). A systematic review of stock market prediction using machine learning and statistical techniques. *Materials Today: Proceedings*, 49, 3187–3191.
6. Politis, D. N., & Romano, J. P. (1994). The Stationary Bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
7. Harvey, C. R., Liu, Y., & Zhu, H. (2016). ...and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 29(1), 5–68.

※ 4~7번은 § 6.4의 block/stationary bootstrap 및 Benjamini–Hochberg 다중비교 보정 절차의 방법론적 근거로 함께 인용된다. 최종 제출 전 추가 문헌(FinBERT 원 논문(Araci, 2019), Cohen's κ /ICC/Krippendorff's α 측정 타당성 문헌 등)을 § 6.2.1 관련 근거로 보강할 수 있다.

부록 A. 예상 심사 질문 및 대응 위치

발표 준비 시 체크리스트로 활용한다.

#	예상 질문	본문 대응 절
1	왜 1일 horizon인가?	§ 5.4
2	09:30 직전 뉴스가 정말 Open 체결에 반영된다고 가정하는가?	§ 5.4 (cut-off 09:25 + 실행 여유 5분)
3	장중·시간외(after-hours) 뉴스는 어떻게 처리하는가?	§ 5.4
4	target과 실제 체결 P&L은 일치하는가?	§ 5.4
5	여러 뉴스의 종목-day aggregation에서 relevance는 어떻게 정의하는가?	§ 5.6 (API 티커 태깅 기반 결정론적 규칙)
6	같은 뉴스의 syndication/republishation을 어떻게 제거하는가?	§ 5.5
7	왜 event clustering 4시간 / cosine 0.85인가?	§ 5.5 (validation set F1 기반 선택)
8	S&P 500 historical membership이 실제 point-in-time인가?	§ 5.1 (경로 A/B/C)
9	VADER/FinBERT/LLM score scale을 어떻게 공정하게 맞췄는가?	§ 5.7 (z-score / 순위 정규화)
10	Teacher-Student를 쓰면 실제 연구 대상 LLM은 무엇인가?	§ 6.2 (Plan A의 GPT-4o 직접 생성분, Plan C는 선택적 부가 기여)
11	Primary metric은 정확히 무엇인가?	§ 6.4 (비용 차감 후 연율화 샤프비율 단일 지표)
12	6개 모델과 여러 국면에 대한 다중비교는 어떻게 통제하는가?	§ 6.4 (계층화 + BH 보정)
13	정확도 향상과 실제 투자성과 향상의 관계를 어떻게 설명하는가?	§ 6.4 Primary, § 6.5
14	FinGPT 대비 정확한 novelty는 무엇인가?	§ 2, § 4
15	12개월 내 완료가 가능한가?	§ 9.2 (Fail-fast 판정 기준 및 범위 축소 우선순위)
16	H1이 성립해도 H2가 성립하지 않을 수 있는데, 논문의 핵심 주장은 무엇인가?	§ 3.2 (H1·H2 계층 관계)
17	FinBERT의 3-class 확률을 어떻게 하나의 스칼라 점수로 바꿨는가?	§ 5.6.1 (scalarization 수식)
18	정규화 시 훈련 구간 내부에서도 록어헤드가 발생하지 않는가?	§ 5.7 (rolling 252일 point-in-time 정규화)
19	시간감쇠 half-life는 왜 6시간인가?	§ 5.6 (사전 고정 + 3h/12h 민감도)
20	임계값 선택에 사용한 데이터를 최종 성능 평가에 재사용하지는 않았는가?	§ 5.5 (threshold selection bias 방지 — validation/test 분리)
21	Plan B로 표본을 줄일 때 체리피킹 편향은 없는가?	§ 6.2 (사전 정의된 기계적 필터링 규칙)